Видобування великих даних

Yelp

Big Data Analysis Project

Аналіз · Масштабованість · Обробка · SQL

Виконавці:

Олексій Горишевський
Данило Шляхетко
Ілля Мацько
Труш Соломія

Навчальний заклад:

НУ "Львівська політехніка"

Кафедра СШІ
Група ШІ-32

Apache Spark Framework · Yelp Open Dataset · 2026

Підготовчий етап: Фундамент проекту

Розподіл ролей та перші кроки для роботи з великими даними Yelp

Розподіл ролей

- **О. Горишевський:** Налаштування репозиторію
- **Д. Шляхетко:** Аналіз датасету Yelp
- **І. Мацько:** Оформлення структури проекту
- **Т. Соломія:** Конфігурація гілок та .gitignore

Технічна реалізація

1. Середовище:
Встановлення PySpark для паралельних обчислень та ініціалізація Git репозиторію (main/dev).

2. Пайплайн даних (download.py):
Автоматизоване скачування, перевірка цілісності, розпаковка JSON та логування результатів паралельно для кількох джерел.

Етап налаштування: Docker та PySpark

Інфраструктура та середовище розробки

РОЗПОДІЛ РОЛЕЙ

Олексій Горишевський

Створення Dockerfile та образу

КЛЮЧОВІ ПРОЦЕСИ DOCKERFILE

- Використання образу Java JDK
- Синхронізація Python-залежностей через uv
- Створення безпечного користувача

НАЛАШТУВАННЯ SPARK

- Конфігурація Java та інсталяція pyspark
- Створення точки входу (main.py)
- Тестування DataFrame (.show())

Крок 02

Етап видобування (Extraction Stage)

Створення схем даних та модулів для завантаження у Spark DataFrame

ОПИС ПРОЦЕСУ

Трансформація сирих даних

Описано перетворення даних із JSON-файлів у структуровані Spark DataFrames для зручної подальшої обробки.

РОЗПОДІЛ РОЛЕЙ

- **О. Горишевський:** Модуль Spark сесії
- **Д. Шляхетко:** Notebook для тестування
- **І. Мацько:** Spark-схеми для таблиць
- **Т. Соломія:** Функціонал завантаження даних

Приклад схеми (tip_schema):

```
from pyspark.sql.types import StructType, StructField, StringType, IntegerType

tip_schema = StructType([
   StructField("text", StringType(), True),
   StructField("date", StringType(), True),
   StructField("compliment_count", IntegerType(), True),
   StructField("business_id", StringType(), True),
   StructField("user_id", StringType(), True)
])
```

Етап трансформації: Бізнес-аналіз

Відповіді на ключові питання щодо Yelp Dataset (Business Schema)

Q1

Топ-10 міст за активністю

Лідер: **Філадельфія** (10.5k закладів). Аналіз активних бізнесів через groupBy.

Q2

Популярність по штатах

Топ-5 бізнесів у кожному регіоні. Використано **Window Functions**.

Q3

Середній рейтинг по штатах

Пенсільванія (3.70), Флорида (3.76), Луїзіана (3.88).

Q4

Топ бізнесів Пенсільванії

Лідер: **Reading Terminal Market** (5.7k відгуків, 4.61★).

Q5

Відхилення від середнього

Ідентифікація еталонних закладів через Window Avg за містом.

Q6

Високорейтингові ресторани

Фільтрація: rating ≥ 4.5, reviews ≥ 100. Приклад: Hattie B's.

Відповідальний за етап: **Ілля Мацько (business schema)** • Інструментарій: Apache Spark SQL & Window Functions

Етап трансформації: Аналіз користувачів

Відповіді на ключові питання щодо Yelp Dataset (User Schema)

Q1

Елітні користувачі

Лідер: **Mike** (12.5k підписників). Критерії: ≥100 fans та ≥500 відгуків.

Q2

Статистика активності

Когортний аналіз за роком реєстрації. Рівень залученості падає з часом.

Q3

Впливовість у когортах

Ранжування за корисними голосами. Лідер 2009: **Fox** (206k голосів).

Q4

Автори підказок (Tips)

Лідер: **Michael** (4,071 підказка). Аналіз співвідношення кількість/якість.

Q5

Якість елітних відгуків

Топ-відгук: 360 корисних голосів. Елітні користувачі — ядро контенту.

Q6

Ранг за компліментами

Лідер: **Richard** (324k компліментів). Використано percent_rank.

Відповідальний за етап: **Олексій Горишевський (user schema)** • Інструментарій: PySpark SQL & Window Functions

Етап трансформації: Аналіз відгуків

Відповіді на ключові питання щодо Yelp Dataset (Review Schema)

Q1

Високо оцінені корисні відгуки

Критерії: ≥10 корисних голосів та 4-5 зірок. Топ-відгук: **404 голоси** (2012 р.).

Q2

Темпоральний аналіз активності

Експоненційне зростання з 2005 р. Тренд на зниження середнього рейтингу з часом.

Q3

Останні відгуки закладів

Використано **row_number** для ідентифікації свіжого стану та популярності бізнесу.

Q4

Топ-20 популярних бізнесів

Лідер: **Acme Oyster House** (7.6k відгуків). Join між таблицями Review та Business.

Q5

Найкращі заклади харчування

Аналіз 5-зіркових відгуків для категорії "Food". Лідер: **Grimaldi's Pizzeria**.

Q6

Кумулятивна динаміка

Наростаючий підсумок через **Window.unboundedPreceding**. Аналіз життєвого циклу.

Відповідальна за етап: **Труш Соломія (review schema)** • Інструментарій: PySpark SQL & Window Functions

Етап трансформації: Аналіз залучення

Відповіді на ключові питання щодо Yelp Dataset (Engagement Metrics)

Q1

Підказки після 2020 року

Пошук tips з ≥3 компліментами. Виявлено **8 підказок**, що свідчить про зміну залученості в пост-пандемічний період.

Q2

Топ локацій за чек-інами

Лідер: **Philadelphia International Airport** (52k чек-інів). Транспортні вузли генерують найбільший трафік.

Q3

Лідери підказок за містами

Використано **rank()** для ідентифікації локальних лідерів. Приклад: El Limon в Ambler (68 tips).

Q4

Мультимедійна активність

Аналіз бізнесів з фото та tips. Лідер: **Café Du Monde** (2.5k підказок та 528 фотографій).

Q5

Популярні відкриті заклади

Фільтрація: ≥4.0 зірок та ≥10 підказок. Поєднання якості сервісу та активності спільноти.

Q6

Частота створення контенту

Обчислення інтервалів через **lag()**. Аналіз патернів поведінки від щоденних до епізодичних записів.

Етап запису результатів

Фіналізація та експорт оброблених даних для подальшого аналізу

1 CSV Експорт

Збереження отриманих результатів у .csv файли для всіх 6 основних таблиць датасету Yelp.

2 Parquet Формат

Використання Parquet для оптимізації структури, забезпечення відтворюваності та продуктивності.

3 Column Lineage

Створення JSON-файлу для відстеження походження стовпців та аудиту трансформацій.

Висновки та перспективи

Підбиття підсумків проекту та визначення векторів подальшого розвитку

1 Успішна реалізація

Побудовано повний конвеєр обробки Yelp датасету (10.4 млн записів) з використанням Apache Spark та Docker.

2 Ефективність даних

Досягнуто мінімальних втрат (лише 81 запис) при значному розширенні схем для глибокого аналізу.

3 Майбутні кроки

Інтеграція моделей машинного навчання для предиктивної аналітики та розширення на нові джерела даних.

Ключовий результат

Проект підтвердив масштабованість Apache Spark для обробки мільйонів записів та важливість структурованого підходу до Data Engineering. Створений конвеєр є повністю відтворюваним та готовим до аудиту.

Дякую за увагу!