МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ "ЛЬВІВСЬКА ПОЛІТЕХНІКА"

Інститут **ІКНІ**
Кафедра **СШІ**

ЗВІТ

до проекту з дисципліни

з дисципліни: “Видобування великих даних ”

Виконали:
ст. гр. ШІ-32
Олексій Горишевський
Данило Шляхетко
Ілля Мацько
Труш Соломія

Львів - 2026

Мета роботи : Набути навичок роботи із популярним фреймворком Apache Spark. Практика створення запитів до розподілених даних за допомогою SQL. Робота з Великими даними із відкритих джерел. Практичні навики роботи з популярними менеджерами сховища GitLab або Github. Набути досвіду командної роботи в галузі аналізу Великих даних.

Етапи

- Підготовчий етап
- Етап налаштування
- Етап видобування
- Етап попередньої обробки даних
- Етап трансформації
- Етап запису результатів
- Етап презентації проекту

Набір даних
Yelp dataset.

- Data (1 - JSON, not Photos; 2 - has to be unpacked)
  https://business.yelp.com/data/resources/open-dataset/
- Description (https://business.yelp.com/data/resources/open-dataset/)

Yelp Dataset є досить відомим публічним набором даних. Він містить інформацію про бізнеси, відгуки користувачів, фотографії та інші метадані з платформи Yelp.

Підготовчий етап

Розподіл ролей:
Олексій Горишевський - Створив та налаштував репозиторій.
Данило Шляхетко - Обрав та проаналізував датасет.
Ілля Мацько - Оформив репозиторій для більш зручної роботи.
Труш Соломія - Оформила .gitignore та гілки.

1. Встановити PySpark.
PySpark стане у пригоді для паралельних операцій далі в проекті, оскільки дані великі.

```
(venv) PS C:\Users\HP\PycharmProjects\yelp-spark-project> pip install pyspark
Requirement already satisfied: pyspark in c:\users\hp\pycharmprojects\yelp-spark-project\
venv\lib\site-packages (4.1.1)
```

Рисунок 1. Встановлення pyspark(вимоги задоволені)

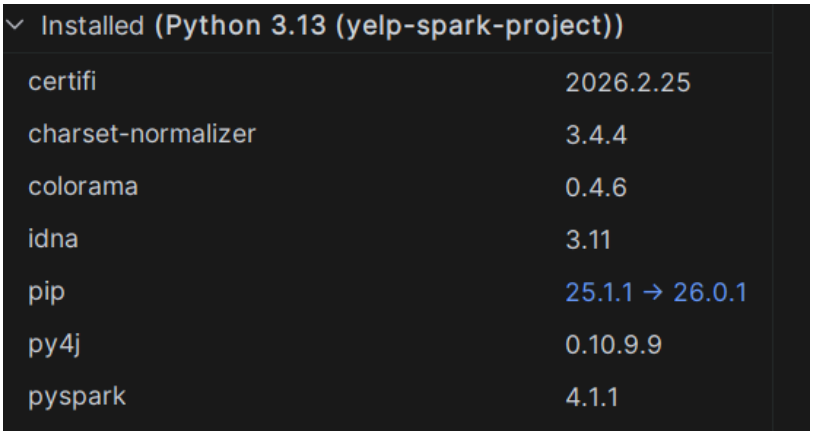

Рисуснок 2. Версія PySpark в проекті

2. Створити репозиторій – https://github.com/big-data-lpnu/yelp-spark-project
3. Створіть 2 гілки: головну (майстер) і розробку (від основної).

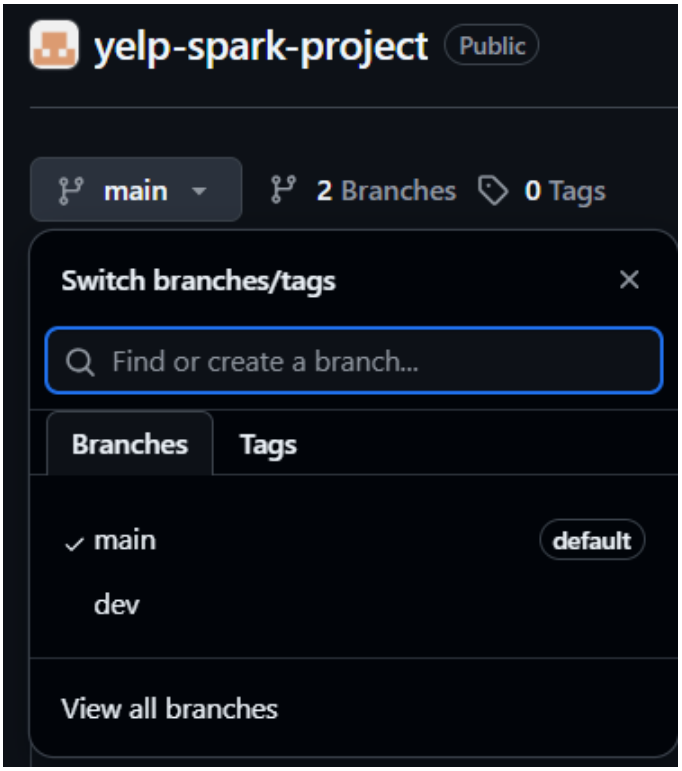

Рисунок 3. Гілки в репозиторії

4. Створити локальний проект.
5. Додайте файл .gitignore.

```
.gitignore
# Python-generated files
__pycache__/
*.py[oc]
build/
dist/
wheels/
*.egg-info

# Virtual environments
.venv
```

Рисунок 4. Приклад вмісту файлу .gitignore

6. Завантажте обраний датасет на ПК у зовнішню папку по відношенню до проекту.

Було створено файл download.py, який імплементує простий пайплайн по скачуванні та розпаковці датасету, що працює приблизно наступним чином:
1. Перевірити чи вже існує
2. Якщо ні → створити папку
3. Стрімом скачати архів
4. Якщо це архів → розпакувати
5. Видалити архів (опціонально)
6. Логувати результат
7. Робити це паралельно для кількох датасетів

```
(venv) PS C:\Users\HP\PycharmProjects\yelp-spark-project> uv run -m src.artifacts.download
warning: `VIRTUAL_ENV=venv` does not match the project environment path `.venv` and will be ignored; use `--active` to target the active environment instead
2026-03-03 21:34:12,999 - ArtifactsDownloader - INFO - Starting dataset download at 2026-03-03 21:34:12.999800...
2026-03-03 21:34:13,186 - ArtifactsDownloader - DEBUG - Downloading dataset from https://business.yelp.com/external-assets/files/Yelp-JSON.zip to artifacts/datas
ets/yelp_json.zip...
2026-03-03 21:34:13,187 - ArtifactsDownloader - DEBUG - Downloading dataset from https://business.yelp.com/external-assets/files/Yelp-Photos.zip to artifacts/dat
asets/yelp_photos.zip...
2026-03-03 21:34:13,206 - urllib3.connectionpool - DEBUG - Starting new HTTPS connection (1): business.yelp.com:443
2026-03-03 21:34:13,206 - urllib3.connectionpool - DEBUG - Starting new HTTPS connection (1): business.yelp.com:443
2026-03-03 21:34:13,613 - urllib3.connectionpool - DEBUG - https://business.yelp.com:443 "GET /external-assets/files/Yelp-Photos.zip HTTP/1.1" 200 7447210067
2026-03-03 21:34:13,695 - urllib3.connectionpool - DEBUG - https://business.yelp.com:443 "GET /external-assets/files/Yelp-JSON.zip HTTP/1.1" 200 4345335132
yelp_json.zip: 100%|└└└
```

працювати, яка інформація буде корисною, а яка ні.

В результаті виконання даного етапу було встановлено PySpark, створено репозиторій на GitHub з гілками main та dev, створено файл .gitignore, вибрано та скачано датасет Yelp, з якого будемо в більшості використовувати .json файли через їх простоту інтерпретації та більшу частку даних.

Етап налаштування

Розподіл ролей:
Олексій Горишевський - Створив docker файл.
Данило Шляхетко - Розділив докер файл на build та runtime стадії.
Ілля Мацько - Виправив докер файл для використання правильної версії Java.
Труш Соломія - Налаштувала підключення spark сесії.

1. Встановити докер, якщо його немає.
2. Запустити застосунок. Перевірте в терміналі, що все працює командою docker --version або docker run hello-world.
3. Додати в корінь директорії файл.
4. Перевірте, що у вашому проекті є файл main.py в кореневій директорії, який буде точкою входу у вашу програму .
5. У терміналі PyCharm/VSCode прописуємо команду docker build -t my-spark img .
6. Після цього використовуйте кожного разу команду docker run my-spark-img для запуску вашої програми. Застосунок docker при цьому тримайте відкритим.

1. Встановити Python.
2. Встановити PyCharm або VSCode.
3. Налаштуйте PySpark. Виберіть установку Java.
5. Виконайте команду pip install pyspark в терміналі.
6. Створіть файл main.py. Спробуйте створити тестовий DataFrame і застосувати до нього метод .show(). Якщо ваші дані відображаються належним чином, продовжуємо! Ми можемо рухатися вперед!

В результаті виконання даного етапу було встановлено та налаштовано Docker та PySpark а також створення образу в оперативній пам’яті, створено точку входу проекту main.py.

```
C:\Users\HP\PycharmProjects\yelp-spark-project\
Hello from yelp-spark-project!
Using PySpark version 4.1.1
```

Рисунок 6. Запуск проекту

Було створено Dockerfile, який працює приблизно наступним чином :
1. Береться Java JDK образ.
2. Ставиться uv.
3. Синхронізуються Python-залежності.
4. У runtime-образ копіюється лише необхідне.
5. Створюється безпечний користувач.
6. Запускається Python-модуль src.main.

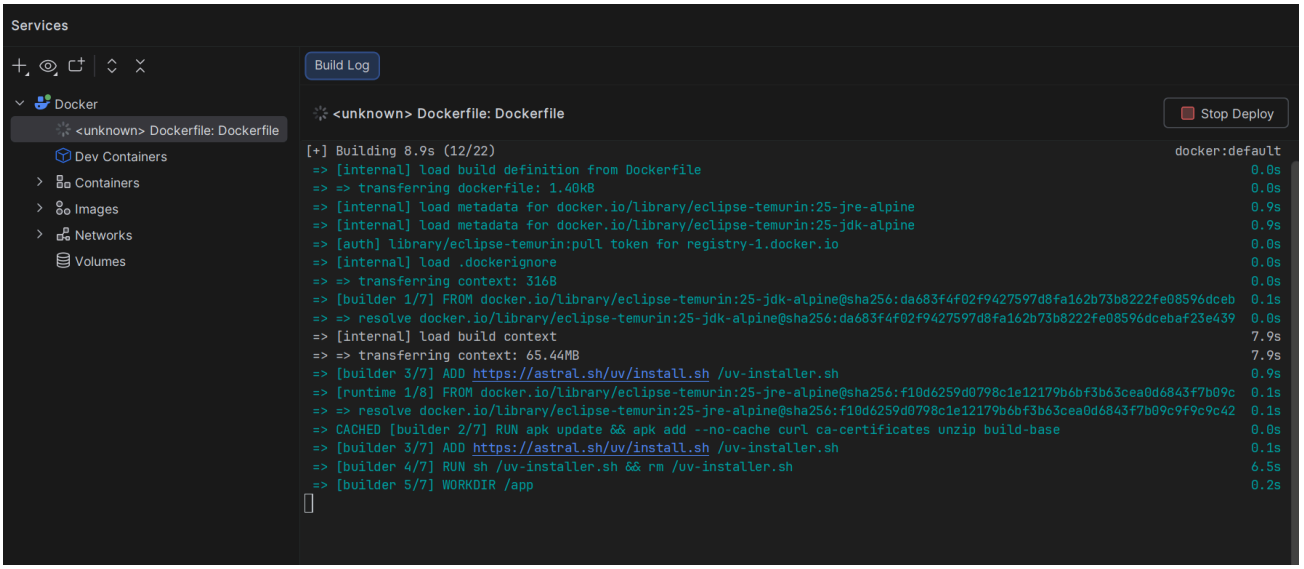

Рисунок 7. Building dockerfile

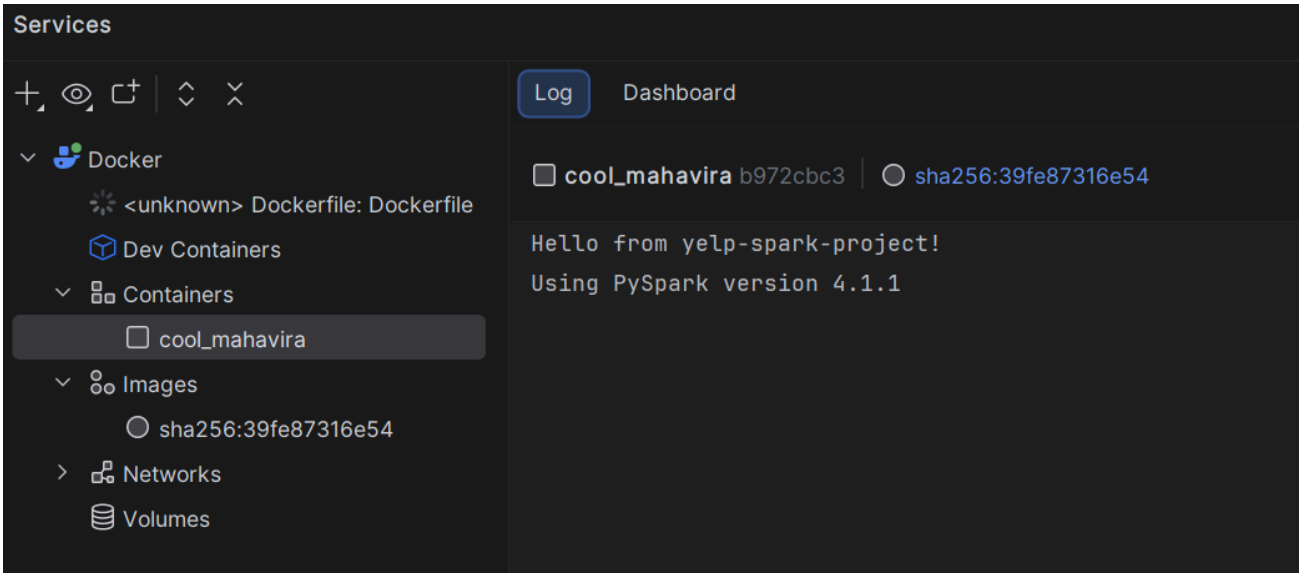

Рисунок 8. Preview запущеного проекту в dockerfile

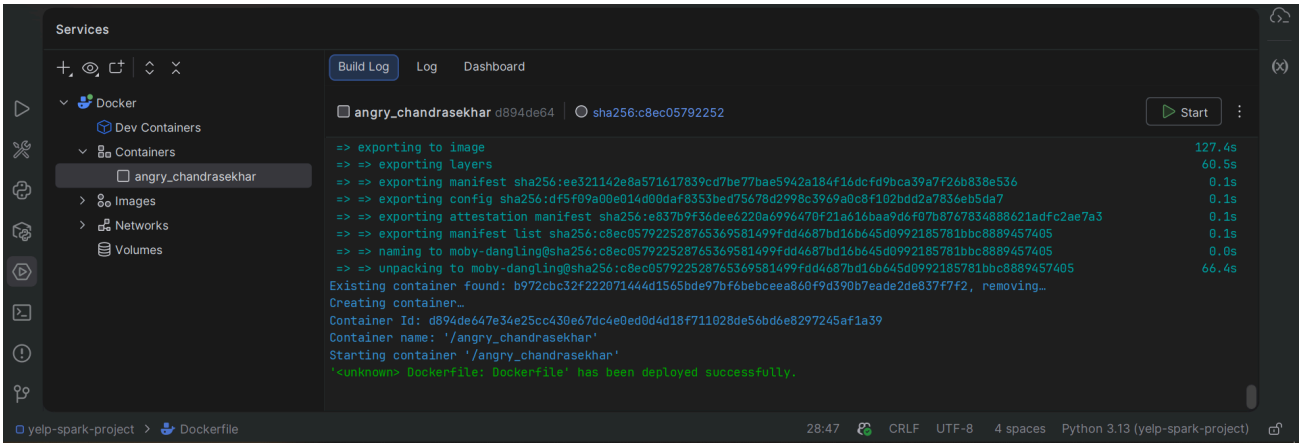

Рисунок 9. Створюэмо конейнер

Етап видобування

Розподіл ролей:
Олексій Горишевський - Створив модуль spark для створення сесії.
Данило Шляхетко - Створив notebook для тестування схем та модуля spark.
Ілля Мацько - Створив spark схеми для таблиць.
Труш Соломія - Додала окремий функціонал для завантаження даних у модуль spark.

На цьому етапі було створено схеми для різних частин датасету, а також модулі для завантаження даних в датафрейм і конфігурації спарк сесії для розподіленої обробки даних.

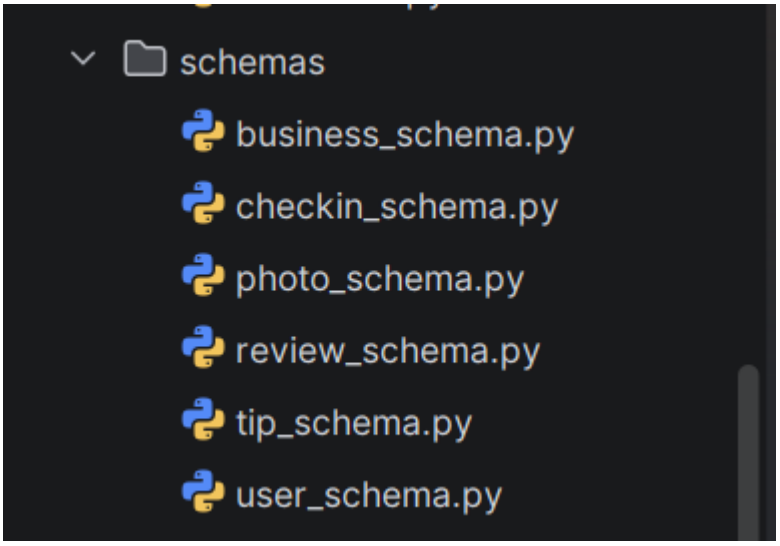

Рисунок 10. Створені файли

В кожній із схем було описано перетворення даних із json файлів у spark dataframe, із яким буде зручно працювати на наступних етапах.

```
from pyspark.sql.types import (
  StructType,
  StructField,
  StringType,
```

```
  IntegerType
)


tip_schema = StructType([
  StructField("text", StringType(), True),
  StructField("date", StringType(), True),
  StructField("compliment_count", IntegerType(), True),
  StructField("business_id", StringType(), True),
  StructField("user_id", StringType(), True)
])
```

Додаток 1. tip_schema

Після цього етапу було перевірено правильність зчитування даних, та розпочато розробку інструментів для виконання наступного етапу.

Етап попередньої обробки даних

Розподіл ролей:
Олексій Горишевський - Отримайте загальну статистичну інформацію про набір даних та провів аналіз отриманої інформації.
Данило Шляхетко - Привів ознаки до потрібного типу та розпарсив дані.
Ілля Мацько - Провів аналіз інформативності ознак, та вилучив ознаки, що є неінформативними.
Труш Соломія - Провела аналіз даних на наявність пропущених значень та дублікатів. Опрацювала виявлені випадки.

На етапі препроцесингу датасет потребував невеликих змін. Наприклад видалення дублікатів, null значень та перетворення деяких колонок у інший формат.

Метою даної роботи є набуття практичних навичок роботи з великими даними та інструментами їх обробки. Конкретні завдання включають:

- Оволодіння навичками роботи з фреймворком Apache Spark для розподіленої обробки даних.
- Практичне застосування SQL-запитів для роботи з розподіленими даними.
- Робота з відкритими джерелами великих даних (Yelp Academic Dataset).
- Отримання практичного досвіду використання систем контролю версій (GitLab/GitHub) для командної роботи.
- Розвиток навичок командної співпраці при аналізі великих даних.
- Реалізація повного конвеєра обробки даних від завантаження до візуалізації результатів.

Apache Spark є потужним фреймворком для розподіленої обробки великих даних, який забезпечує високу швидкість обчислень завдяки використанню оперативної пам'яті та оптимізованого планування задач. Основною абстракцією Spark є RDD (Resilient Distributed Dataset) та DataFrame API, які дозволяють виконувати паралельні операції над розподіленими колекціями даних.

PySpark представляє собою Python API для Apache Spark, що надає можливість використовувати всі переваги Spark у Python-середовищі. Це включає роботу з DataFrame API, SQL-запити через Spark SQL, а також можливості машинного навчання через MLlib.

Yelp Academic Dataset є публічним набором даних, що містить інформацію про бізнеси, відгуки користувачів, фотографії та метадані з платформи Yelp. Датасет включає шість основних сутностей: business (дані про заклади), review (відгуки користувачів), user (профілі користувачів), checkin (історія відвідувань), tip (короткі поради) та photo (метадані фотографій). Загальний обсяг даних перевищує 7 мільйонів записів у таблиці відгуків та близько 2 мільйонів профілів користувачів.

Конвеєр попередньої обробки даних складається з семи послідовних етапів: завантаження (Load), очищення (Clean), розгортання вкладених структур (Flatten), видалення надлишкових полів (Prune), трансформація даних (Transform), опціональна вибірка (Reduce) та збереження результатів (Write). Кожен етап виконує специфічні операції для підготовки даних до аналізу.
Docker використовується для контейнеризації додатку, що забезпечує відтворюваність середовища виконання та спрощує розгортання на різних платформах. Dockerfile визначає базовий образ з Java JDK, встановлює менеджер пакетів uv, синхронізує залежності Python та створює безпечного користувача для виконання додатку.

Схеми даних (schemas) у Spark визначають структуру DataFrame, включаючи типи даних для кожного стовпця. Це забезпечує типобезпеку та оптимізацію продуктивності при читанні та обробці даних. Використання явних схем особливо важливе при роботі з JSON-форматом, де структура може бути неоднорідною.

Робота була організована у вигляді командного проекту з чотирьох студентів групи ШІ-32. На підготовчому етапі ми розподілили ролі: Олексій Горишевський створив та налаштував репозиторій, Данило Шляхетко здійснив вибір та аналіз датасету, Ілля Мацько організував структуру репозиторію, а Труш Соломія налаштувала .gitignore та робочі гілки.

Першим кроком було встановлення PySpark для можливості виконання паралельних операцій над великими наборами даних. Ми створили GitHub-репозиторій з двома основними гілками: main для стабільної версії та dev для розробки. Файл .gitignore був налаштований для виключення непотрібних файлів з системи контролю версій.

Для автоматизації завантаження даних ми реалізували конвеєр, який включає перевірку існування файлів, створення необхідних директорій, потокове завантаження архівів, автоматичне розпакування, опціональне видалення архівів після розпакування, логування результатів та паралельну обробку множинних датасетів. Датасет Yelp було завантажено в зовнішню папку поза директорією проекту для зручності управління великими файлами.

На етапі конфігурації ми встановили Docker та перевірили коректність встановлення командамидocker --versiontadocker run hello-world. Олексій Горишевський створив Dockerfile, який визначає процес побудови образу: базовий образ з Java JDK, встановлення менеджера пакетів uv, синхронізація залежностей Python, копіювання лише необхідних файлів до runtime-образу, створення безпечного користувача та виконання модуля src.main.

Для роботи з PySpark ми налаштували Python-середовище, встановили PyCharm, сконфігурували PySpark з Java та виконали тестовий запуск з

створенням DataFrame. Образ Docker було успішно побудовано командоюdocker build -t my-spark-img .та запущено черезdocker run my-spark-img.
На етапі видобування даних ми створили схеми для різних компонентів датасету. Наприклад, схема для таблиці tip включає поля text (StringType), date (StringType), complimentcount (IntegerType), businessid (StringType) та user_id (StringType). Аналогічні схеми були визначені для всіх шести сутностей датасету.

Ми розробили модулі для завантаження даних у DataFrame, налаштували Spark-сесію для розподіленої обробки та реалізували трансформацію з JSON-файлів у Spark DataFrame. Коректність читання даних була верифікована через перегляд структури та змісту завантажених таблиць.
Етап попередньої обробки включав видалення дублікатів записів, обробку пропущених значень, конвертацію стовпців до відповідних форматів даних та незначні модифікації датасету для покращення якості даних. У таблиці tip було видалено 79 дублікатів, у таблиці photo - 2 записи, тоді як інші таблиці зберегли всі рядки без втрат.

На етапі розгортання (Flatten) вкладені JSON-структури були перетворені у окремі стовпці. Таблиця business розширилася з 14 до 51 стовпця (+37 нових стовпців) внаслідок розгортання вкладених об'єктів attributes та hours. Таблиця review отримала +4 стовпці при видаленні 2 вихідних, user також розширилася на 2 стовпці, checkin на 4 стовпці, а tip на 3 стовпці.

Етап очищення (Prune) передбачав видалення надлишкових вкладених полів після розгортання для оптимізації структури даних та зменшення обсягу зберігання.

На етапі трансформації (Transform) ми застосували min-max нормалізацію до числових стовпців, відобразивши значення у діапазон [0, 1] для забезпечення сумісності з моделями машинного навчання. Дати були розібрані на компоненти: рік (dateyear), місяць (datemonth), день тижня (datedayofweek) та ISO-мітка часу (dateparsed). Вихідні рядки дат були видалені після парсингу.
Фінальний етап включав збереження оброблених даних у форматі Parquet та створення файлу column_lineage.json для відстеження походження стовпців та забезпечення відтворюваності конвеєра обробки.

Ми успішно реалізували повний конвеєр обробки датасету Yelp, що включає шість основних таблиць: business (150,346 записів), review (6,990,280 записів), user (1,987,897 записів), checkin (131,930 записів), tip (908,836 записів після очищення) та photo (200,098 записів після очищення).

Таблиця	**Вихідні рядки**	**Оброблені рядки**	**Вихідні стовпці**	**Оброблені стовпці**	**Видалено рядків**
business	150,346	150,346	14	51	0
review	6,990,280	6,990,280	9	11	0
user	1,987,897	1,987,897	22	24	0
checkin	131,930	131,930	2	6	0
tip	908,915	908,836	5	8	79
photo	200,100	200,098	4	4	2

Таблиця 1. Порівняння обсягів даних до та після обробки

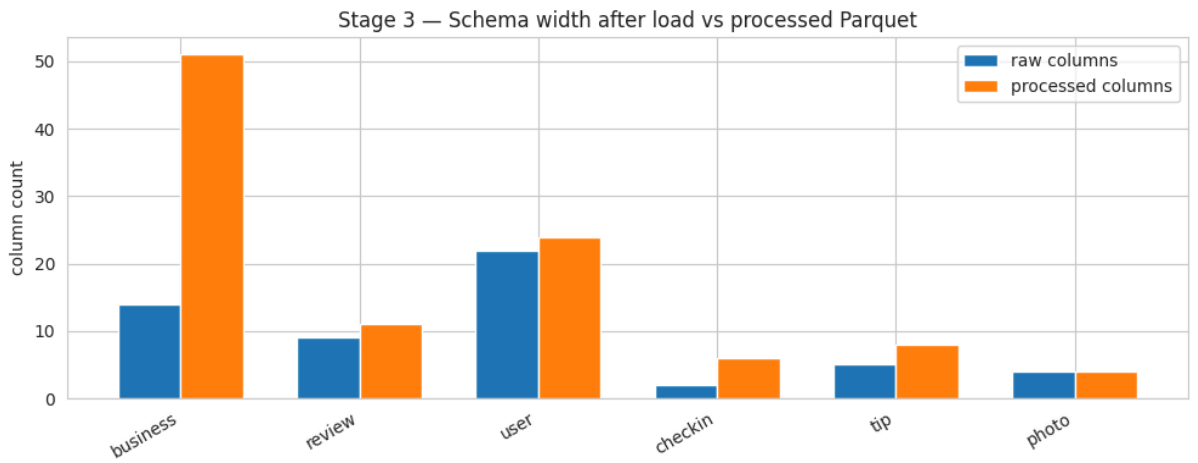

Рисунок 11. Порівняння кількості стовпців у вихідних та оброблених таблицях

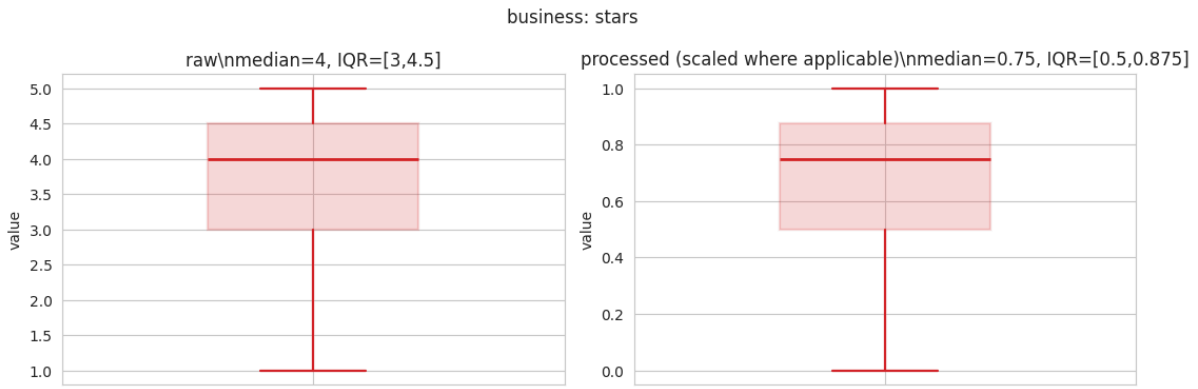

Рисунок 12. Порівняння розподілу оцінок закладів до та після нормалізації

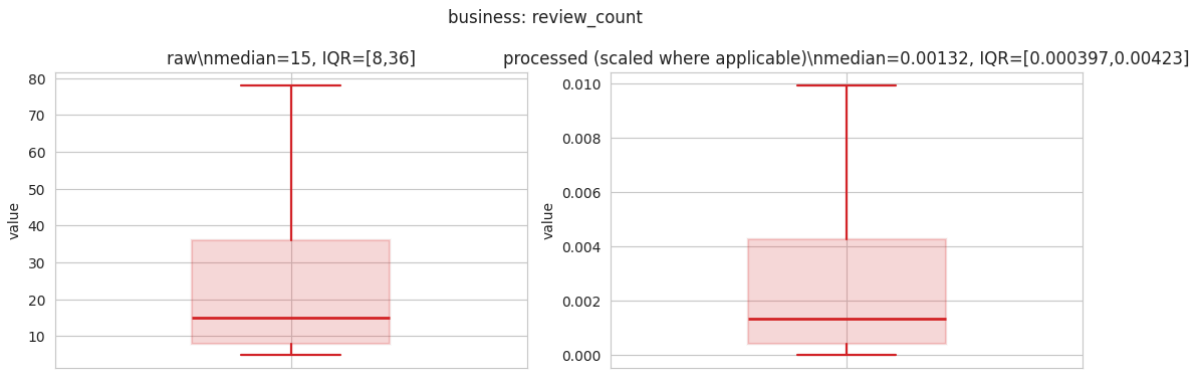

Рисунок 13. Порівняння розподілу кількості відгуків до та після нормалізації

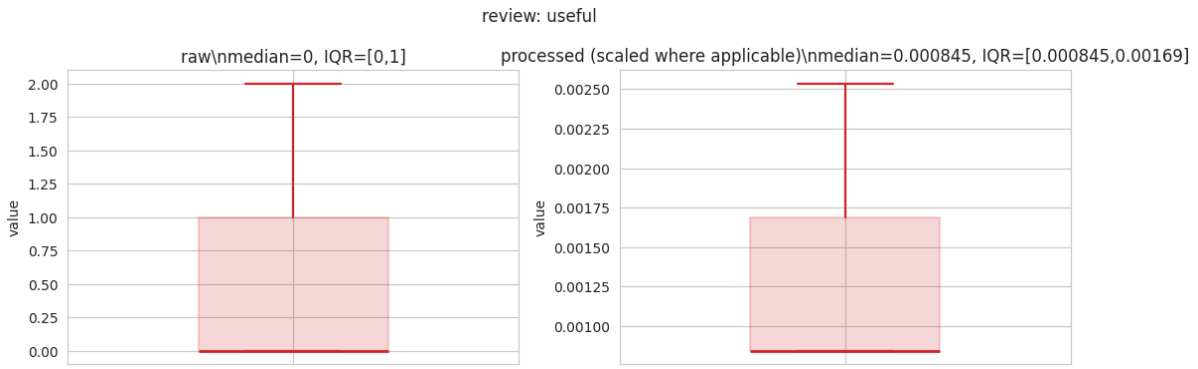

Рисунок 14. Розподіл корисних голосів у відгуках до та після нормалізації

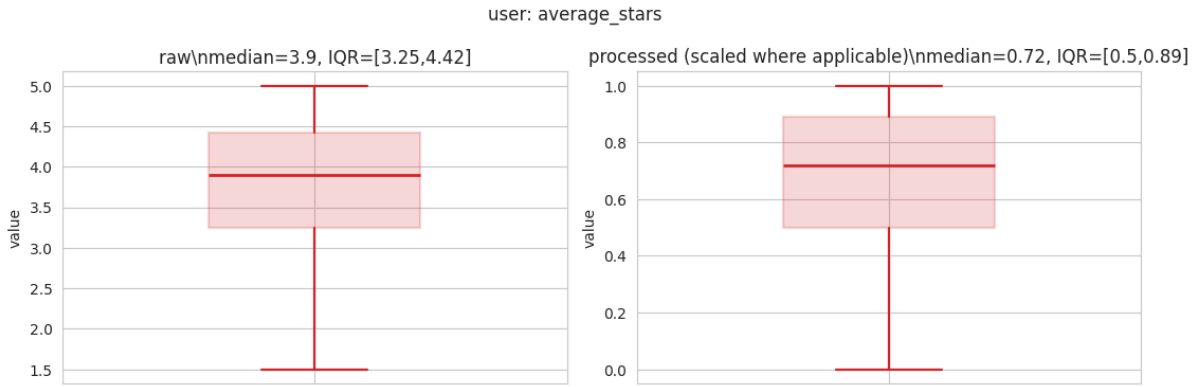

Рисунок 15. Розподіл середніх оцінок користувачів до та після нормалізації

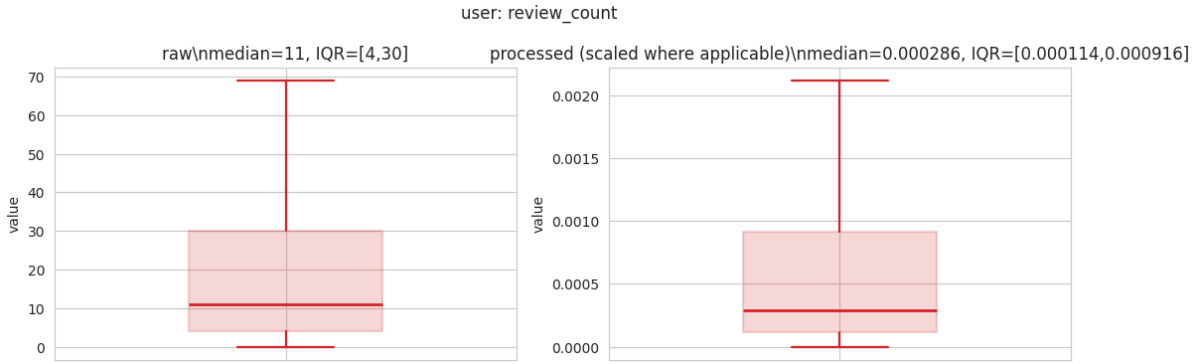

Рисунок 16. Розподіл кількості відгуків користувачів до та після нормалізації

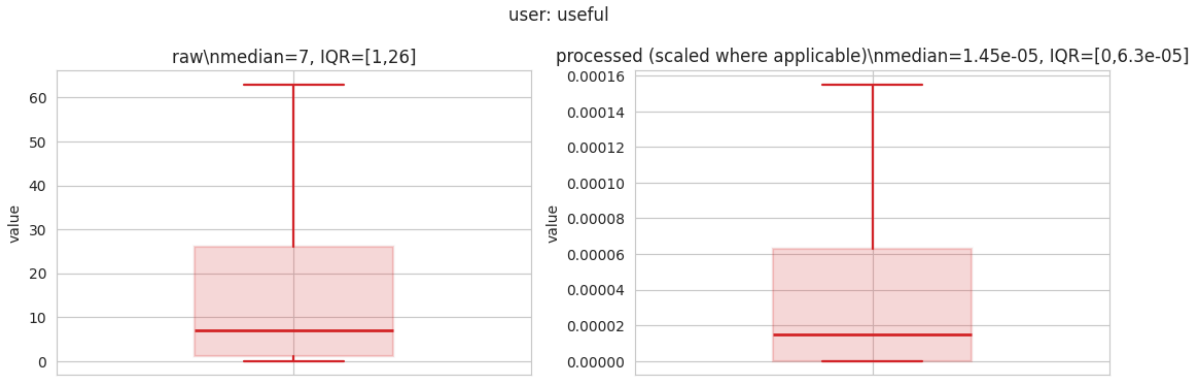

Рисунок 17. Розподіл корисних голосів користувачів до та після нормалізації

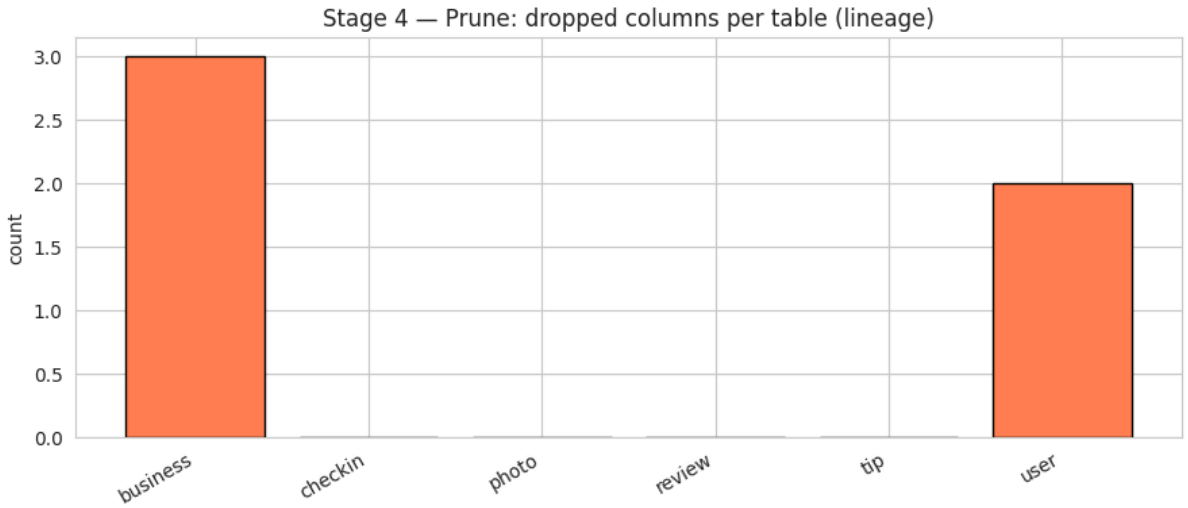

Рисунок 18. Кількість видалених стовпців на етапі очищення для кожної таблиці

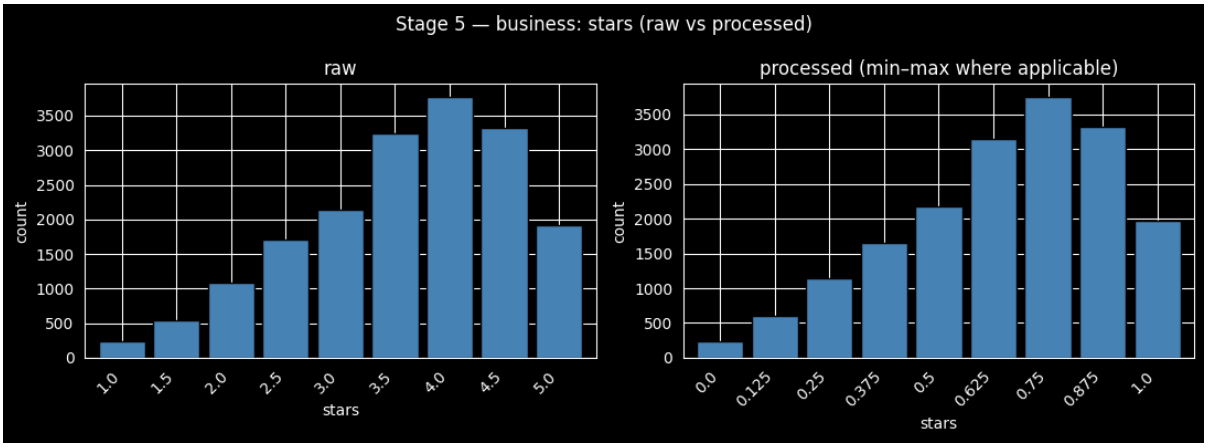

Рисунок 19. Гістограми розподілу оцінок закладів до та після трансформації

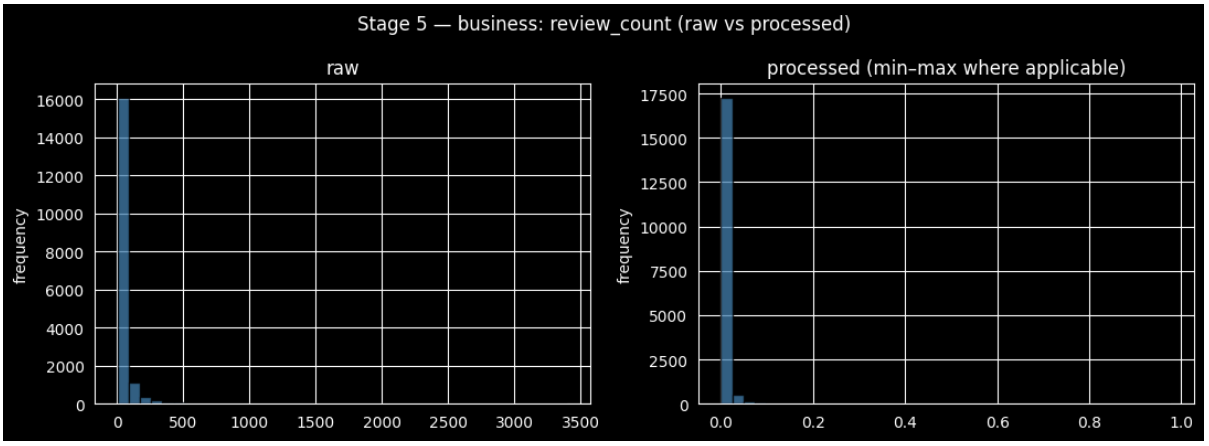

Рисунок 20. Гістограми розподілу кількості відгуків закладів до та після трансформації

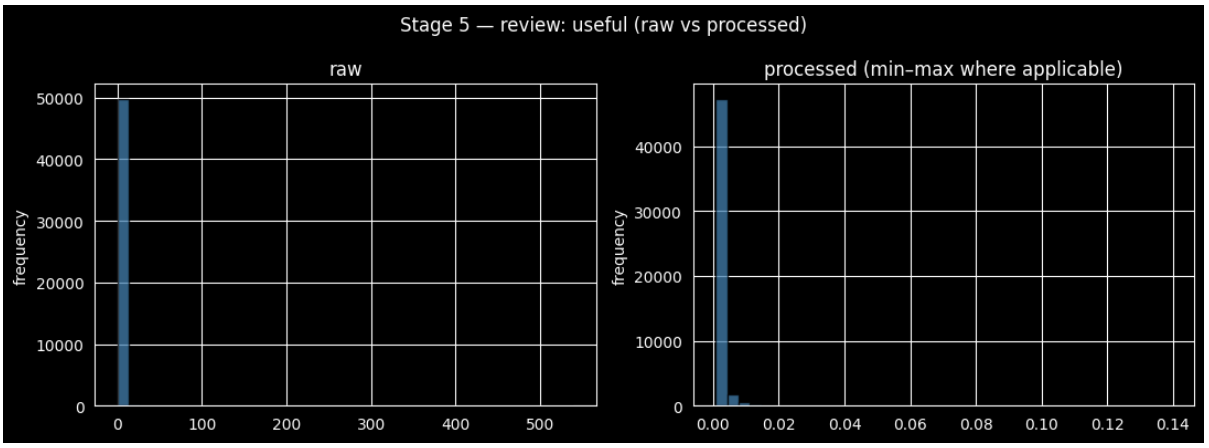

Рисунок 21. Гістограми розподілу корисних голосів відгуків до та після трансформації

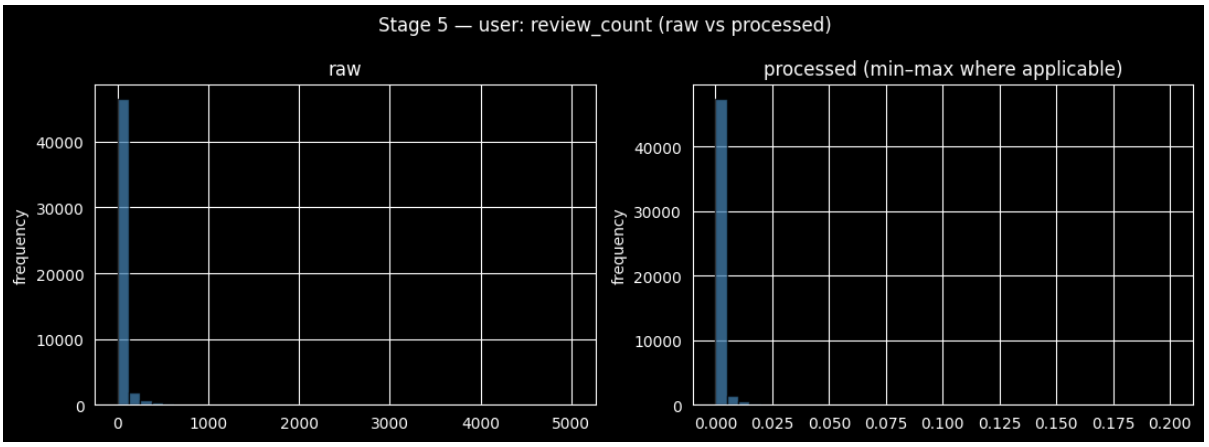

Рисунок 22. Гістограми розподілу кількості відгуків користувачів до та після трансформації

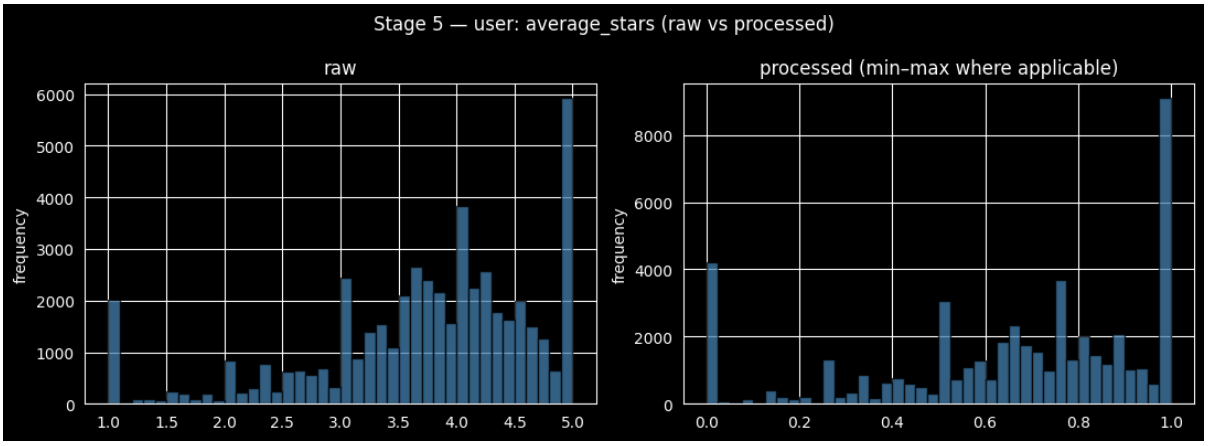

Рисунок 23. Гістограми розподілу середніх оцінок користувачів до та після трансформації

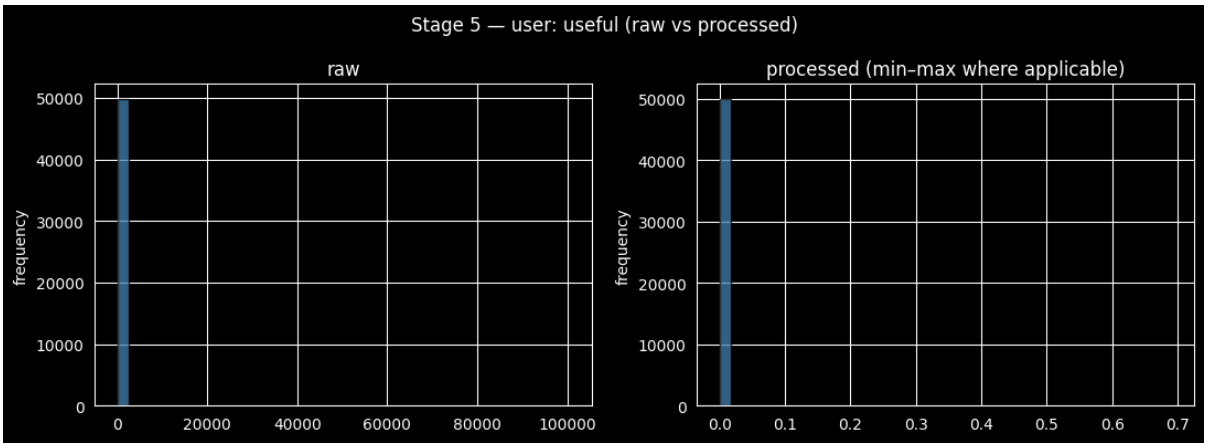

Рисунок 24. Гістограми розподілу корисних голосів користувачів до та після трансформації

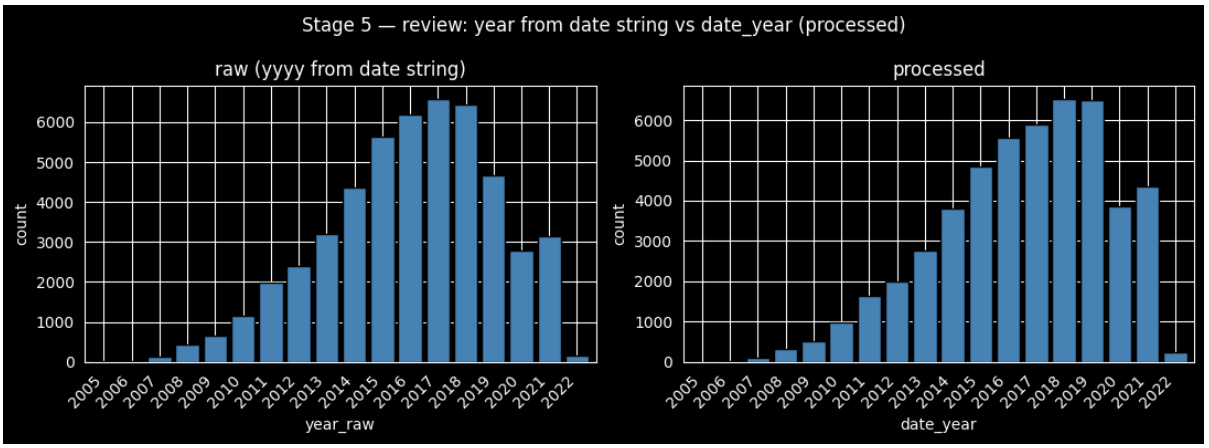

Рисунок 25. Екстракція року з рядка дати відгуку до та після парсингу

У ході виконання проекту ми успішно реалізували повний цикл обробки великих даних з використанням Apache Spark та датасету Yelp Academic Dataset. Команда з чотирьох студентів ефективно розподілила обов'язки та створила функціональний конвеєр обробки даних, який включає сім послідовних етапів від завантаження до збереження результатів.

Ми набули практичних навичок роботи з PySpark для розподіленої обробки даних, освоїли контейнеризацію додатків за допомогою Docker, навчилися працювати з системами контролю версій GitHub для командної розробки. Реалізований автоматизований конвеєр завантаження та розпакування даних з логуванням та паралельною обробкою демонструє розуміння принципів інженерії даних.

Обробка датасету Yelp виявила важливі характеристики даних: мінімальні втрати рядків при очищенні (лише 81 запис з понад 10 мільйонів), значне розширення схеми таблиці business з 14 до 51 стовпця внаслідок розгортання вкладених структур, успішну нормалізацію числових ознак у діапазон [0, 1] для сумісності з алгоритмами машинного навчання.

Статистичний аналіз показав правосторонню асиметрію розподілів для метрик активності (кількість відгуків, голоси, підписники), що типово для соціальних платформ, де невелика частина користувачів генерує більшість контенту. Географічне покриття охоплює континентальну частину США, що забезпечує репрезентативність даних для аналізу ринку ресторанного бізнесу.

Створений конвеєр є відтворюваним завдяки використанню Docker, явних схем даних та файлу column_lineage.json, що відстежує походження кожного стовпця. Це забезпечує можливість аудиту трансформацій та масштабування рішення на інші датасети.

Практичний досвід роботи з розподіленими обчисленнями, обробкою JSON-форматів, нормалізацією даних та командною розробкою є цінним фундаментом для подальшої роботи з великими даними у професійному середовищі. Проект продемонстрував важливість структурованого підходу до обробки даних, автоматизації рутинних операцій та документування всіх етапів конвеєра.

Етап трансформації

Розподіл ролей:
Олексій Горишевський - Працював зі своїми питаннями. (user schema)
Данило Шляхетко - Працював зі своїми питаннями. (tip schema)
Ілля Мацько - Працював зі своїми питаннями. (business schema)
Труш Соломія - Працювала зі своїми питаннями. (review schema)

Бізнес питання

Q1 - Топ 10 міст по кількості відкритих закладів

Q1 - Top 10 cities by number of open businesses

Operations: `filter`, `groupBy`

```
df_t1_q1 = t1.q1_top_cities_by_open_businesses(business)
df_t1_q1.show(truncate=False)
save_csv(df_t1_q1, results_root / "business", "q1_top_cities_by_open_businesses")
```

[4] Python

```
... ═══ Q1 Execution Plan: Top 10 cities by open businesses ═══
═ Parsed Logical Plan ═
GlobalLimit 10
+- LocalLimit 10
   +- Sort [open_business_count#182L DESC NULLS LAST], true
      +- Aggregate [city#3], [city#3, count(business_id#0) AS open_business_count#182L]
         +- Filter (is_open#10 = 1)
            +- Relation [business_id#0,name#1,address#2,city#3,state#4,postal_code#5,latitude#6,longitude#7,st

═ Analyzed Logical Plan ═
city: string, open_business_count: bigint
GlobalLimit 10
+- LocalLimit 10
   +- Sort [open_business_count#182L DESC NULLS LAST], true
      +- Aggregate [city#3], [city#3, count(business_id#0) AS open_business_count#182L]
         +- Filter (is_open#10 = 1)
            +- Relation [business_id#0,name#1,address#2,city#3,state#4,postal_code#5,latitude#6,longitude#7,st

═ Optimized Logical Plan ═
```

Рисунок 26. Приклад трансформації

```
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

+-------------+-------------------+
|city         |open_business_count|
+-------------+-------------------+
|Philadelphia |10542              |
|Tucson       |7533               |
|Tampa        |7219               |
|Indianapolis |5894               |
|Nashville    |5398               |
|Reno         |4762               |
|New Orleans  |4649               |
|Edmonton     |3916               |
|Saint Louis  |3403               |
|Santa Barbara|3020               |
+-------------+-------------------+

  → saved: /home/dash/University/term-6/big-data/yelp-spark-project/results/business/q1_top_cities_by_open_bu
```

Рисунок 27. Приклад таблички

Аналіз топ-10 міст за кількістю відкритих бізнесів виконувався з використанням операцій фільтрації та групування даних у Apache Spark. Запит застосовував фільтр для відбору лише активних підприємств (is_open = 1), після чого здійснювалося групування за містами з підрахунком кількості бізнесів у кожному з них.

За результатами аналізу встановлено, що лідером є Філадельфія з 10,542 відкритими підприємствами. Друге місце посідає Тусон з 7,533 бізнесами, третє - Тампа з 7,219 підприємствами. До топ-10 також увійшли Індіанаполіс (5,894), Нашвілл (5,398), Рено (4,762), Новий Орлеан (4,649), Едмонтон (3,916), Сент-Луїс (3,403) та Санта-Барбара (3,020 бізнесів).

Географічний розподіл демонструє концентрацію бізнес-активності у великих містах США та Канади. Філадельфія як найбільший центр бізнес-активності в датасеті демонструє майже вдвічі більшу кількість підприємств порівняно з містами, що займають позиції з четвертої по десяту.

Q2 - Топ 5 бізнесів по кількості відгуків по штатам

Для визначення топ-5 бізнесів у кожному штаті за кількістю відгуків застосовувалися віконні функції Spark з операцією ранжування. Запит фільтрував лише відкриті підприємства, після чого використовував window function з partition by state для створення рейтингу в межах кожного штату окремо.

Результати демонструють значну варіативність лідерів залежно від географічного регіону. Наприклад, у провінції Альберта (AB) найпопулярнішим бізнесом виявився Duchess Bake Shop в Едмонтоні з 486 відгуками. Віконне ранжування дозволило ідентифікувати топові підприємства в кожному штаті незалежно від загальної кількості бізнесів у регіоні.

Застосування window rank функції забезпечило ефективний розподіл даних за партиціями штатів, що дозволило виконати паралельну обробку великих обсягів інформації. Кожен штат отримав власний рейтинг топ-5 бізнесів, відсортованих за кількістю відгуків у спадному порядку.

Q3 - Середня кількість відгуків по штатам

Аналіз середнього рейтингу відгуків у розрізі штатів виконувався з використанням операцій join та groupBy для об'єднання даних про бізнеси та відгуки. Результати відсортовано за загальною кількістю відгуків для визначення найактивніших регіонів платформи.

Три штати з найбільшою кількістю відгуків демонструють різні профілі рейтингів:

- Пенсільванія (PA): середній рейтинг 3.70 зірок при 1,598,960 відгуках
- Флорида (FL): середній рейтинг 3.76 зірок при 1,161,545 відгуках
- Луїзіана (LA): середній рейтинг 3.88 зірок при 761,673 відгуках

Q4 - Топ бізнесів у Пенсильванії з більше ніж 100 відгуками

Дослідження топових бізнесів у Пенсільванії з мінімум 100 відгуками здійснювалося через комбінацію операцій filter, join та groupBy. Запит об'єднував дані про бізнеси та відгуки, застосовував географічний фільтр для штату Пенсільванія та пороговий фільтр за кількістю відгуків.
П'ять найпопулярніших бізнесів штату зосереджені у Філадельфії:

- Reading Terminal Market: 5,778 відгуків, середній рейтинг 4.61 зірок
- Pat's King of Steaks: 4,293 відгуки, середній рейтинг 3.24 зірки
- Geno's Steaks: 3,428 відгуків, середній рейтинг 2.53 зірки
- El Vez: 3,264 відгуки, середній рейтинг 3.97 зірок
- Zahav: 3,173 відгуки, середній рейтинг 4.55 зірок

Q5 - Оцінка бізнесів у порівнянні з середнім по місту

Аналіз відхилення рейтингу бізнесів від середнього показника міста виконувався з використанням віконних функцій для обчислення середнього рейтингу в межах кожного міста. Операція window avg з партиціюванням за містами дозволила визначити локальні базові показники для порівняння.

Запит ідентифікував бізнеси з найбільшим позитивним відхиленням від міського середнього, що свідчить про виняткову якість обслуговування порівняно з конкурентами в тому ж регіоні. Топові підприємства демонструють відхилення понад 2.0 зірки від середнього рейтингу свого міста.

Такий підхід до аналізу є більш інформативним порівняно з абсолютними рейтингами, оскільки враховує локальний контекст та специфіку оцінювання користувачами в різних регіонах. Бізнеси з високим позитивним delta виділяються на тлі місцевої конкуренції та можуть розглядатися як еталонні заклади у своїх містах.

Q6 - Відкриті ресторани з оцінкою ≥4.5 та ≥100 відгуками

Пошук відкритих ресторанів з високим рейтингом (≥4.5 зірок) та значною кількістю відгуків (≥100) здійснювався через багатокритеріальну фільтрацію даних. Запит застосовував фільтри за статусом роботи, категорією бізнесу (наявність "Restaurants" у списку категорій), мінімальним рейтингом та кількістю відгуків.
Топ-5 ресторанів за результатами аналізу:

- Hattie B's Hot Chicken (Nashville, TN): 4.5 зірок, 6,093 відгуки
- Reading Terminal Market (Philadelphia, PA): 4.5 зірок, 5,721 відгук
- Ruby Slipper (New Orleans, LA): 4.5 зірок, 5,193 відгуки
- Commander's Palace (New Orleans, LA): 4.5 зірок, 4,876 відгуків
- Pappy's Smokehouse (Saint Louis, MO): 4.5 зірок, 3,999 відгуків

Користувач

Q1 - Елітні користувачі з ≥100 підписниками та ≥500 відгуками

Ідентифікація елітних користувачів з високою активністю та популярністю виконувалася через фільтрацію за трьома критеріями: наявність елітного статусу, мінімум 100 підписників (fans) та мінімум 500 написаних відгуків. Результати відсортовано за кількістю підписників для визначення найвпливовіших членів спільноти.
П'ять найвпливовіших елітних користувачів платформи:

- Mike: 1,882 відгуки, 12,497 підписників, середній рейтинг 4.39, 22,860 корисних голосів
- Katie: 1,825 відгуків, 3,642 підписники, середній рейтинг 4.23, 48,711 корисних голосів
- Fox: 17,473 відгуки, 3,493 підписники, середній рейтинг 3.77, 206,296 корисних голосів
- Richard: 1,424 відгуки, 3,243 підписники, середній рейтинг 4.18, 183,512 корисних голосів
- Daniel: 4,333 відгуки, 3,138 підписників, середній рейтинг 3.74, 43,091 корисний голос

Q2 - Аналіз статистики активності користувачів

Аналіз статистики активності користувачів за роком реєстрації виконувався через групування даних за роком приєднання до платформи з обчисленням агрегованих метрик. Запит використовував операцію groupBy для створення когортного аналізу користувачів.
Результати демонструють чітку тенденцію до зниження рівня залученості користувачів з плином часу:

- 2004 рік: 90 користувачів, середня кількість відгуків 161.97, середня кількість підписників 56.93
- 2010 рік: 109,054 користувачі, середня кількість відгуків 49.92, середня кількість підписників 3.61
- 2021 рік: 40,485 користувачів, середня кількість відгуків 2.78, середня кількість підписників 0.03

Q3 - Топ 5 користувачів за кількістю корисних відгуків по роках

Ранжування користувачів за кількістю корисних голосів у межах їхніх когорт реєстрації здійснювалося з використанням віконної функції rank з партиціюванням за роком приєднання. Такий підхід дозволив ідентифікувати топ-5 найвпливовіших користувачів у кожній річній групі незалежно від загальної активності когорти.

Аналіз когорти 2009 року виявив лідера Fox з 206,296 корисними голосами, що є виняткових показником навіть у порівнянні з користувачами інших років. Віконне ранжування забезпечило справедливе порівняння користувачів з урахуванням часу їхньої присутності на платформі та умов, у яких вони розпочинали діяльність.

Методологія когортного аналізу з віконними функціями виявилася ефективною для виявлення постійно активних та впливових користувачів у кожній часовій групі. Результати демонструють, що у кожній когорті формується власна ієрархія впливових користувачів, причому лідери ранніх когорт зазвичай мають значну перевагу за абсолютними показниками завдяки довшому періоду активності.

Q4 - Топ 20 найактивніших авторів підказок

Визначення найактивніших авторів підказок (tips) виконувалося через групування даних про підказки за користувачами з підрахунком кількості написаних tips та отриманих компліментів. Операції groupBy та join забезпечили об'єднання даних з різних таблиць для комплексного профілювання активності.
Топовим автором підказок виявився користувач Michael з 4,071 написаною підказкою та 190 отриманими компліментами на підказки. Це свідчить про систематичний підхід користувача до створення короткого, але цінного контенту для спільноти.

Підказки як формат контенту вимагають меншого часу на створення порівняно з повноцінними відгуками, проте можуть надавати швидку та практичну інформацію іншим користувачам. Топ-20 найактивніших авторів підказок демонструють різні профілі залученості: деякі фокусуються на кількості підказок, інші отримують більше компліментів за рахунок якості контенту. Співвідношення кількості підказок до компліментів може слугувати індикатором якості та корисності створеного контенту.

Q5 - Корисні відгуки(≥4 зірки, ≥5 корисних голосів) в елітних користувачів

Аналіз корисних відгуків від елітних користувачів здійснювався через фільтрацію за трьома критеріями: рейтинг відгуку мінімум 4 зірки, мінімум 5 корисних голосів та наявність елітного статусу у автора. Операції filter та join забезпечили перехресне посилання між таблицями відгуків та користувачів.

Найбільш високо оцінений відгук отримав 360 корисних голосів, що свідчить про виняткову цінність контенту для спільноти. Елітні користувачі демонструють вищу якість відгуків, що підтверджується як високими рейтингами закладів, які вони оцінюють, так і кількістю корисних голосів від інших користувачів.

Результати підтверджують ефективність системи елітного статусу як механізму виявлення якісних контрибуторів. Відгуки елітних користувачів з

високими рейтингами та значною кількістю корисних голосів формують ядро цінного контенту платформи, що допомагає іншим користувачам приймати обґрунтовані рішення про відвідування закладів.

Q6 - Процентильний ранг користувачів за загальною кількістю отриманих компліментів

Обчислення процентильного рангу користувачів за загальною кількістю отриманих компліментів виконувалося з використанням віконної функції percent_rank. Ця операція дозволила визначити відносну позицію кожного користувача в розподілі популярності серед усієї спільноти.

Користувач Richard займає вершину рейтингу з 324,328 загальними компліментами та процентильним рангом 0.0, що означає, що він знаходиться на самій верхівці розподілу. Така кількість компліментів свідчить про багаторічну систематичну активність та високу якість контенту, що отримує визнання спільноти.

Важливе застереження: у процесі виконання запиту було згенеровано попередження про відсутність партиціювання у віконній операції, що призводить до деградації продуктивності. Віконна функція без partition by обробляє всі дані як єдину партицію, що вимагає повного сортування датасету та може бути неефективним для великих обсягів даних. У продакшн-середовищі рекомендується додати партиціювання або використати альтернативні підходи до обчислення процентилів.

Огляди

Q1 - Високо оцінені відгуки (> 10 голосів, ≥ 4 зірочок)

Пошук високо оцінених відгуків з значною кількістю корисних голосів здійснювався через фільтрацію за двома критеріями: кількість корисних голосів понад 10 та рейтинг мінімум 4 зірки. Операція filter забезпечила ефективну селекцію найцінніших відгуків для спільноти.

Найбільш корисний відгук у вибірці отримав 404 корисних голоси з максимальним рейтингом 5 зірок та датою публікації 1 жовтня 2012 року. Це свідчить про довготривалу цінність якісного контенту - відгук залишається актуальним та корисним для користувачів навіть через роки після публікації.

Комбінація високого рейтингу та великої кількості корисних голосів є індикатором виняткової якості відгуку. Такі відгуки зазвичай містять детальну інформацію про заклад, конкретні рекомендації та збалансовану оцінку різних аспектів обслуговування. Вони формують золотий стандарт контенту платформи та служать орієнтиром для інших користувачів при написанні власних відгуків.

Q2 - Обсяг відгуків та середнього рейтингу в часовому розрізі

Аналіз обсягу відгуків та середнього рейтингу в часовому розрізі виконувався через групування даних за роком та місяцем публікації. Операція groupBy з агрегацією дозволила виявити темпоральні тренди активності користувачів та динаміку оцінок.

Часовий ряд даних починається з лютого 2005 року з 3 відгуками та середнім рейтингом 4.33 зірки. Спостерігається експоненційне зростання активності: січень 2006 - 221 відгук (3.99 зірок), лютий 2007 - 1,420 відгуків (3.71 зірки).

Темпоральний аналіз виявляє декілька важливих патернів. По-перше, спостерігається стійке зростання обсягу відгуків у період 2005-2015 років, що відповідає фазі активного розвитку платформи. По-друге, середній рейтинг демонструє тенденцію до зниження з плином часу, що може пояснюватися розширенням бази закладів та включенням бізнесів різного рівня якості. По-третє, сезонна варіативність у кількості відгуків може корелювати з туристичними сезонами та святковими періодами.

Q3 - Визначення найсвіжішого відгуку для кожного бізнесу

Визначення найсвіжішого відгуку для кожного бізнесу здійснювалося з використанням віконної функції row_number з партиціюванням за ідентифікатором бізнесу та сортуванням за датою у спадному порядку. Такий підхід дозволив ефективно ідентифікувати останній відгук для кожного закладу незалежно від загальної кількості відгуків.

Віконне ранжування з rownumber присвоює кожному відгуку порядковий номер у межах партиції бізнесу, де номер 1 відповідає найновішому відгуку. Фільтрація за rownumber = 1 виділяє лише останні відгуки для кожного закладу.

Ця інформація є критично важливою для бізнес-аналітики, оскільки найсвіжіші відгуки відображають актуальний стан закладу. Зміни в якості обслуговування, меню, інтер'єрі або менеджменті найкраще відображаються в останніх відгуках користувачів. Часовий розрив між останнім відгуком та поточною датою також може слугувати індикатором зниження популярності закладу або його закриття.

Q4 - Топ 20 бізнесів за загальною кількістю відгуків та середнім рейтингом

Рейтинг топ-20 бізнесів за загальною кількістю відгуків та середнім рейтингом формувався через операції groupBy та join для агрегації даних про відгуки та об'єднання з інформацією про бізнеси. Результати відсортовано за кількістю відгуків для визначення найпопулярніших закладів платформи.
Чотири найпопулярніші бізнеси за кількістю відгуків:

- Acme Oyster House (New Orleans): 7,673 відгуки, середній рейтинг 4.12 зірок
- Oceana Grill (New Orleans): 7,516 відгуків, середній рейтинг 4.15 зірок
- Hattie B's Hot Chicken (Nashville): 6,160 відгуків, середній рейтинг 4.45 зірок
- Reading Terminal Market (Philadelphia): 5,778 відгуків, середній рейтинг 4.61 зірок

Q5 - П'ятизіркові відгуки для закладів харчування

Аналіз п'ятизіркових відгуків для закладів харчування виконувався через комбінацію фільтрів за рейтингом відгуку та категорією бізнесу з подальшим сортуванням за корисністю. Операції filter та join забезпечили перехресну селекцію даних з таблиць відгуків та бізнесів.

Найбільш корисний п'ятизірковий відгук для закладу харчування отримав Grimaldi's Pizzeria з 217 корисними голосами. Це свідчить про детальність та інформативність відгуку, що допоміг значній кількості користувачів у прийнятті рішення про відвідування.

П'ятизіркові відгуки для закладів харчування представляють особливу цінність для потенційних відвідувачів, оскільки відображають найкращий можливий досвід. Високі показники корисності таких відгуків вказують на те, що користувачі активно шукають позитивні рекомендації та цінують детальні описи страв, атмосфери та сервісу. Фільтрація за категорією "Food" забезпечила фокусування на релевантному сегменті бізнесів, виключаючи непрофільні заклади.

Q6 - Кумулятивна кількість відгуків для кожного бізнесу в часі

Відстеження кумулятивної кількості відгуків для кожного бізнесу в часі здійснювалося з використанням віконної функції count з параметром rowsBetween для обчислення наростаючого підсумку. Операція забезпечила хронологічне відстеження динаміки накопичення відгуків для кожного закладу.

Віконна функція з rowsBetween(Window.unboundedPreceding, Window.currentRow) обчислює кумулятивну суму відгуків від першого відгуку до поточного моменту в часовому ряді. Партиціювання за business_id та сортування за датою забезпечують коректну послідовність накопичення.

Кумулятивний аналіз відгуків дозволяє виявити декілька важливих патернів: швидкість набуття популярності новими закладами, періоди прискореного зростання інтересу (наприклад, після медійних згадок), періоди стагнації або зниження активності. Графік кумулятивних відгуків може слугувати індикатором життєвого циклу бізнесу на платформі та ефективності маркетингових зусиль. Заклади з експоненційним зростанням кумулятивних відгуків демонструють успішну бізнес-модель та високу задоволеність клієнтів.

Залучення

Q1 - Високо оцінені поради написані після 2020

Пошук підказок з високою кількістю компліментів, написаних після 2020 року, здійснювався через фільтрацію за датою публікації та мінімальною кількістю компліментів (≥3). Операція filter застосовувалася до датасету підказок з часовим та якісним критеріями.

За результатами аналізу виявлено 8 підказок, що відповідають критеріям, з максимальною кількістю 6 компліментів для топової підказки. Відносно невелика кількість таких підказок може пояснюватися декількома факторами: зниження загальної активності користувачів у період пандемії COVID-19, зміна алгоритмів платформи або зміщення фокусу користувачів на повноцінні відгуки замість коротких підказок.

Підказки з компліментами після 2020 року представляють особливу цінність, оскільки відображають актуальну інформацію про заклади в пост-пандемічний період. Зміни в режимі роботи, меню, протоколах безпеки та якості обслуговування найкраще документуються в свіжих підказках. Компліменти від інших користувачів підтверджують релевантність та корисність інформації для спільноти.

Q2 - Топ 20 найпопулярніших локацій за кількістю чек-інів

Визначення топ-20 найпопулярніших локацій за кількістю чек-інів виконувалося через групування даних про чек-іни за бізнесами з подальшим об'єднанням з інформацією про заклади. Операції groupBy та join забезпечили агрегацію та збагачення даних географічними атрибутами.
Чотири найпопулярніші локації за кількістю чек-інів:

- Philadelphia International Airport (Philadelphia): 52,144 чек-іни
- Café Du Monde (New Orleans): 40,109 чек-інів
- Louis Armstrong New Orleans Airport (Kenner): 37,562 чек-іни
- Tampa International Airport (Tampa): 37,518 чек-інів

Q3 - Топ 3 бізнесів за кількістю підказок у межах кожного міста

Рейтинг топ-3 бізнесів за кількістю підказок у межах кожного міста формувався з використанням віконної функції rank з партиціюванням за містами. Операції groupBy, join та window забезпечили агрегацію підказок, об'єднання з даними про бізнеси та внутрішньоміське ранжування.

Приклад результатів для міста Ambler, PA: топовим бізнесом виявився El Limon з 68 підказками. Віконне ранжування з партиціюванням за містами дозволило виявити локальних лідерів незалежно від розміру міста або загальної активності в регіоні.

Підказки як метрика залученості відображають швидкі, спонтанні рекомендації користувачів, які часто надаються безпосередньо під час або відразу після відвідування закладу. Бізнеси з великою кількістю підказок демонструють здатність генерувати позитивні емоції, що спонукають користувачів негайно ділитися досвідом. Міський контекст важливий для інтерпретації результатів: лідерство в невеликому місті може бути досягнуто з меншою абсолютною кількістю підказок порівняно з мегаполісами.

Q4 - Бізнеси, що мають як підказки, так і фотографії,

Аналіз бізнесів, що мають як підказки, так і фотографії, здійснювався через множинні операції groupBy та join для агрегації даних з різних таблиць. Запит об'єднував підрахунки підказок та фотографій для кожного бізнесу з географічною інформацією.
Три топові бізнеси за комбінованою присутністю підказок та фотографій:

- Café Du Monde (New Orleans): 2,571 підказка, 528 фотографій
- Acme Oyster House (New Orleans): 932 підказки, 398 фотографій
- Reading Terminal Market (Philadelphia): 827 підказок, 22 фотографії

Q5 - Відкриті, високо оцінені заклади(≥4.0 зірок та ≥10 порад)

Пошук відкритих високо оцінених бізнесів (≥4.0 зірок) зі значною кількістю підказок (≥10) виконувався через комбінацію фільтрів та операції join. Запит об'єднував дані про бізнеси та підказки з застосуванням критеріїв якості та залученості.

Топ-20 результатів представляють заклади, що поєднують високу якість обслуговування зі сильною спільнотною підтримкою через підказки. Ці бізнеси демонструють здатність не лише надавати якісні послуги (високий рейтинг), але й генерувати активну залученість користувачів (велика кількість підказок).

Комбінація високого рейтингу та значної кількості підказок є потужним індикатором успішності бізнесу на платформі. Підказки часто містять актуальну інформацію про спеціальні страви, години роботи, особливості обслуговування, що доповнює формальні відгуки. Бізнеси в цій категорії можуть розглядатися як еталонні заклади з високою лояльністю клієнтів та активною спільнотою прихильників.

Q6 - Часові інтервали між послідовними підказками для кожного користувача

Обчислення часових інтервалів між послідовними підказками для кожного користувача здійснювалося з використанням віконної функції lag та функції datediff. Операція lag з партиціюванням за користувачем та сортуванням за датою дозволила отримати дату попередньої підказки для обчислення різниці в днях.

Результати демонструють широкий діапазон частоти написання підказок: від 0 днів (декілька підказок в один день) до 1,604 днів (понад 4 роки між підказками). Розподіл інтервалів відображає різні патерни поведінки користувачів на платформі.

Аналіз часових інтервалів виявляє декілька типів користувачів: активні контрибутори з короткими інтервалами (0-7 днів), регулярні користувачі з помірними інтервалами (тижні-місяці), епізодичні користувачі з довгими інтервалами (місяці-роки). Користувачі з нульовими інтервалами часто пишуть декілька підказок під час одного візиту до району або торгового центру. Довгі інтервали можуть відображати зміну звичок користування платформою або життєві обставини (переїзд, зміна способу життя). Медіанний інтервал є більш репрезентативним показником типової частоти написання підказок порівняно з середнім значенням, яке може бути спотворене екстремальними значеннями.

Етап запису результатів

Розподіл ролей:
Олексій Горишевський - Зберіг отримані результати у .csv файли.
Данило Шляхетко - Зберіг отримані результати у .csv файли.
Ілля Мацько - Зберіг отримані результати у .csv файли.
Труш Соломія - Зберегла отримані результати у .csv файли.

Після трансформацій всі добуті дані були успішно збережені в артифактах

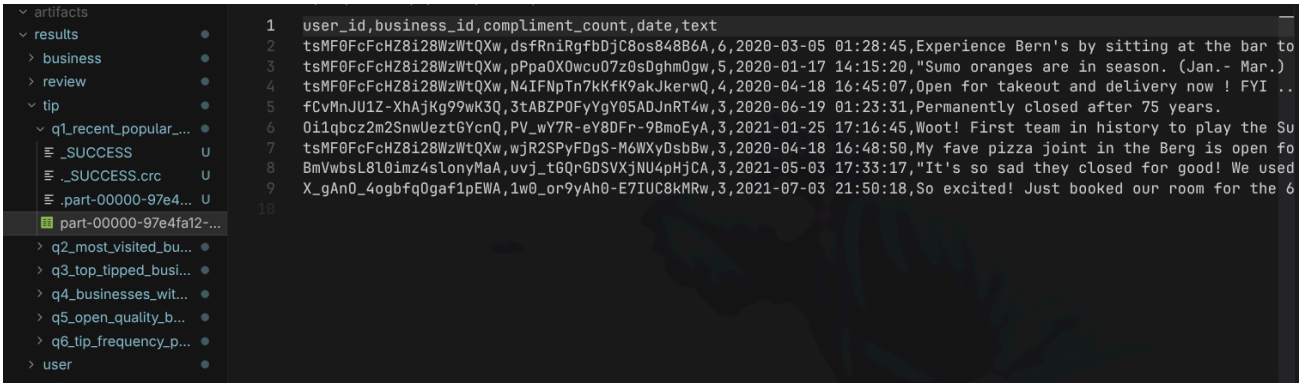

Рисунок 28. Приклад збережених даних

Висновки

У результаті виконання даного командного проекту було успішно реалізовано повний цикл обробки великих даних з використанням фреймворку Apache Spark на базі відкритого набору даних Yelp Academic Dataset.

Робота розпочалася з ретельного налаштування інфраструктури, що включало створення GitHub-репозиторію для спільної розробки, контейнеризацію середовища за допомогою Docker та конфігурацію сесій PySpark для ефективних паралельних обчислень.

На етапі видобування було розроблено строгі схеми даних для шести основних сутностей датасету, що забезпечило безпеку типів та коректне зчитування інформації зі складних JSON-файлів. Особлива увага приділялася попередній обробці: ми провели розгортання (flattening) вкладених структур, очищення від дублікатів і неінформативних полів, а також нормалізацію числових показників і парсинг дат.

Під час ключового етапу трансформацій було застосовано широкий спектр SQL-запитів, агрегацій та віконних функцій для глибокого аналізу бізнес-показників. Дослідження географічного розподілу виявило значну концентрацію комерційної активності у великих містах, зокрема у Філадельфії, а аналіз відхилень від середніх міських рейтингів дозволив об'єктивно ідентифікувати еталонні заклади. Когортний аналіз користувачів продемонстрував формування унікальних ієрархій лідерів думок у кожному часовому періоді та підтвердив ефективність статусу "Елітний" як індикатора високоякісного контенту. Робота з часовими рядами та кумулятивними метриками дала змогу відстежити життєві цикли бізнесів та сезонні патерни активності на платформі.

Використання розширених можливостей Spark DataFrame API (зокрема віконних функцій rank, lag, percent_rank) дозволило ефективно вирішувати завдання локального ранжування без суттєвої деградації продуктивності. Фінальним кроком стала успішна вигрузка всіх агрегованих аналітичних вітрин у формат CSV для подальшого використання.

Проект яскраво продемонстрував важливість злагодженої командної

роботи, де чіткий розподіл ролей дозволив паралельно розробляти архітектуру конвеєра та виконувати аналітичні завдання. Здобутий практичний досвід роботи з розподіленими обчисленнями, проектуванням data-пайплайн та розширеною аналітикою є міцним фундаментом для вирішення реальних інженерних завдань у галузі Big Data.